บทที่ 2
ทฤษฎีและวรรณกรรมที่เกี่ยวข้อง

2.1 ข้าว

ข้าวในประเทศไทยถือเป็น "ศาสตร์แห่งแผ่นดิน" ที่มีความสำคัญอย่างยิ่ง โดยมีชื่อทางวิทยาศาสตร์ว่า Oryza sativa L. จัดอยู่ในวงศ์ Gramineae, โครงสร้างของเมล็ดข้าวประกอบด้วยส่วนสำคัญคือ ข้าวเปลือก (Whole grain rice) ที่มีเปลือกหุ้ม, ข้าวกล้อง (Brown rice) ซึ่งเป็นเมล็ดที่กะเทาะเปลือกออกแต่ยังมีจมูกข้าวและรำข้าว และ ข้าวสาร (White rice) ซึ่งเป็นส่วนของเนื้อเมล็ดหรือเอนโดสเปิร์มที่สะสมแป้งเป็นหลัก กระบวนการเจริญเติบโตของเมล็ดข้าวหลังจากผสมเกสรและปฏิสนธิ มีลำดับขั้นที่สำคัญคือ ระยะข้าวเป็นน้ำนม (ประมาณวันที่ 8), ระยะข้าวเม่า (ประมาณวันที่ 14) และจะพัฒนาจนเป็นเมล็ดแก่เต็มที่พร้อมเก็บเกี่ยวได้ในช่วง 25 - 30 วัน อาจเปรียบได้ว่า ข้าวของประเทศไทยไม่ได้เป็นเพียง "อาหารมื้อหลัก" แต่เป็น "ขุมทรัพย์ทางชีวภาพ" ที่ผ่านการเจียระไนด้วยนวัตกรรมและเทคโนโลยี เพื่อยกระดับจากสินค้าเกษตรพื้นฐานไปสู่ผลิตภัณฑ์ที่ดูแลสุขภาพและคุณภาพชีวิตของผู้คนอย่างยั่งยืน [1]

โรคข้าวคือสภาวะที่ต้นข้าวแสดงอาการผิดปกติอันเนื่องมาจากการเข้าทำลายของเชื้อโรคหรือปัจจัยแวดล้อมที่ไม่อื้ออำนวย ซึ่งสภาวะผิดปกติดังกล่าวอาจมีสาเหตุมาจากสิ่งมีชีวิต เช่น เชื้อรา แบคทีเรีย ไวรัส ไฟโตพลาสมา และไส้เดือนฝอย หรืออาจเกิดจากสิ่งไม่มีชีวิต เช่น การสะสมของก๊าซพิษในดิน จุลินทรีย์เหล่านี้สามารถเข้าทำลายและทำให้ข้าวแสดงอาการผิดปกติได้อย่างชัดเจนในเกือบทุกส่วนของต้น ไม่ว่าจะเป็นใบ ลำต้น กาบใบ รวง และเมล็ด โดยลักษณะอาการที่พบโดยทั่วไปได้แก่ การที่ต้นข้าวมีขนาดเตี้ยแคระแกร็น ใบมีสีผิดปกติไปจากเดิม เช่น อาการด่างซีดหรือเปลี่ยนเป็นสีเหลืองและสีส้ม การตายของเนื้อเยื่อที่เป็นจุดหรือแผลขีดแห้ง อาการเหี่ยวที่เกิดจากการอุดตันของท่อน้ำท่ออาหาร ตลอดจนความผิดปกติของโครงสร้างพืช เช่น อาการรากพองเป็นปมหรือดอกกระถิน การเกิดโรคในข้าวนั้นจำเป็นต้องมีความสัมพันธ์ระหว่างปัจจัยหลักสามประการ คือ ต้นข้าวที่อ่อนแอต่อโรค เชื้อโรคที่มีความรุนแรง และสภาพแวดล้อมที่เหมาะสมต่อการเจริญเติบโตของเชื้อ รวมถึงปัจจัยทางการเขตกรรม เช่น การใส่ปุ๋ยไนโตรเจนในอัตราที่สูงเกินไป ซึ่งเป็นตัวกระตุ้นให้โรคบางชนิดระบาดรุนแรงยิ่งขึ้น [2]

2.2 แชทบอท(Chatbot)

Chatbot คือ แอปพลิเคชันซอฟต์แวร์ที่ออกแบบมาเพื่อจำลองการสนทนาของมนุษย์ผ่านการโต้ตอบทางข้อความหรือเสียงเพื่อแก้ไขข้อสงสัยของลูกค้า เมื่อลูกค้าหรือลูกค้าเป้าหมายติดต่อผ่านช่องทางใดๆ แชทบอทจะคอยต้อนรับและแก้ไขปัญหาของพวกเขา นอกจากนี้ยังสามารถช่วยลูกค้ายื่นคำขอรับบริการ ส่งอีเมล หรือเชื่อมต่อกับตัวแทนที่เป็นมนุษย์ได้หากจำเป็นทำความเข้าใจ หลักการทำงานของ Chatbots แชทบอททำงานโดยใช้เทคโนโลยีปัญญาประดิษฐ์ (AI) และการประมวลผลภาษาธรรมชาติ (NLP) เพื่อทำความเข้าใจและตีความภาษาของมนุษย์ เมื่อผู้ใช้โต้ตอบกับแชทบอท มันจะวิเคราะห์อินพุตและพยายามทำความเข้าใจจุดประสงค์ของมัน โดยการเปรียบเทียบคำขอของผู้ใช้กับชุดคำสำคัญและวลีที่กำหนดไว้ล่วงหน้า ซึ่งได้รับการตั้งโปรแกรมไว้ให้จดจำ จากคำสำคัญและวลีเหล่านี้ แชทบอทจะสร้างคำตอบที่คิดว่าเหมาะสมที่สุด โดยแบ่งประเภทของ Chatbot เป็นดังนี้

(1) เมนูหรือแชทบอทตามปุ่ม (Menu or button-based chatbots) แชทบอทตามเมนูหรือตามปุ่ม เป็นแชทบอทพื้นฐานที่สุดที่ผู้ใช้สามารถโต้ตอบด้วยได้โดยการคลิกที่ปุ่มตัวเลือกจากเมนูที่มีสคริปต์ซึ่งตรงกับความต้องการของพวกเขาได้ดีที่สุด ขึ้นอยู่กับสิ่งที่ผู้ใช้คลิก แชทบอทแบบธรรมดาอาจแจ้งตัวเลือกชุดอื่นให้ผู้ใช้เลือกจนกว่าจะถึงตัวเลือกที่เหมาะสมและเฉพาะเจาะจงที่สุด โดยพื้นฐานแล้ว แชทบอทเหล่านี้ทำงานเหมือนกับแผนผังการตัดสินใจ

(2) แชทบอทที่กำหนดคีย์เวิร์ดเอาไว้แล้ว (Rules-based chatbots) แชทบอทประเภทนี้ สร้างจากฟังก์ชันแผนผังการตัดสินใจอย่างง่ายของแชทบอทตามเมนู โดยใช้ตรรกะแบบมีเงื่อนไข ถ้า/แล้ว เพื่อพัฒนาโฟลว์การสนทนาแบบอัตโนมัติ ทำหน้าที่เป็นคำถามที่พบบ่อยเชิงโต้ตอบโดยพื้นฐานแล้ว โปรแกรมออกแบบการสนทนาจะกำหนดชุดตัวเลือกคำถาม และคำตอบไว้ล่วงหน้าเพื่อให้แชทบอทสามารถเข้าใจข้อมูลของผู้ใช้และตอบสนองได้อย่างถูกต้อง

(3) แชทบอทที่ขับเคลื่อนด้วย AI (AI Powered Chatbots) แม้ว่ากระบวนการสนทนาของแชทบอทตามกฎจะรองรับเฉพาะตัวเลือกคำถามและคำตอบที่ถูกกำหนดไว้ล่วงหน้าเท่านั้น แต่แชทบอท AI ก็สามารถเข้าใจคำถามของผู้ใช้ได้ ไม่ว่าจะใช้ถ้อยคำอย่างไรก็ตาม ด้วยความสามารถด้าน AI และความเข้าใจภาษาธรรมชาติ (NLU) บอท AI จึงสามารถตรวจจับข้อมูลในบริบทที่เกี่ยวข้องทั้งหมดที่ผู้ใช้แบ่งปันได้อย่างรวดเร็ว ช่วยให้การสนทนาดำเนินไปได้อย่างราบรื่นและเป็นการสนทนามากขึ้น เมื่อแชทบอทที่ขับเคลื่อนด้วย AI ไม่แน่ใจว่าบุคคลนั้นถามอะไร และพบการกระทำมากกว่าหนึ่งรายการที่สามารถตอบสนองคำขอได้ แชทบอทก็สามารถถามคำถามเพื่อชี้แจงได้ นอกจากนี้ยังสามารถแสดงรายการการดำเนินการที่เป็นไปได้ซึ่งผู้ใช้สามารถเลือกตัวเลือกที่สอดคล้องกับความต้องการของตนได้

(4) แชทบอทเสียง (Voice Chatbots) แชทบอทเสียงเป็นอีกหนึ่งเครื่องมือการสนทนาที่ช่วยให้ผู้ใช้สามารถโต้ตอบกับบอทได้โดยการพูดกับบอทแทนการพิมพ์ แชทบอทเสียงบางตัวอาจเป็นเพียงระบบพื้นฐานซึ่งผู้ใช้บางรายอาจรู้สึกหงุดหงิดกับเทคโนโลยี Interactive Voice Response (IVR) ที่พบ โดยเฉพาะอย่างยิ่งเมื่อระบบไม่สามารถดึงข้อมูลที่ผู้ใช้กำลังมองหาจากตัวเลือกเมนูที่ตั้งโปรแกรมไว้ล่วงหน้าและพักสายผู้ใช้ไว้ อย่างไรก็ตามระบบนี้กำลังพัฒนาด้วยปัญญาประดิษฐ์

(5) แชทบอท AI Generation มีความสามารถนำเสนอฟังก์ชันการทำงานที่ได้รับการปรับปรุงให้ดียิ่งขึ้น ด้วยความคล่องแคล่วในการทำความเข้าใจภาษากลาง ความสามารถในการปรับให้เข้ากับรูปแบบการสนทนาของผู้ใช้ และการใช้ความเห็นอกเห็นใจเมื่อตอบคำถามของผู้ใช้ ในขณะที่แชทบอท AI แบบสนทนาสามารถแยกแยะคำถามหรือความคิดเห็นของผู้ใช้และสร้างการตอบกลับที่เหมือนกับมนุษย์ แต่แชทบอท AI แบบสร้างสรรค์สามารถก้าวไปอีกขั้นด้วยการสร้างเนื้อหาใหม่เป็นเอาต์พุต เนื้อหาใหม่นี้อาจดูเหมือนข้อความ รูปภาพ และเสียงคุณภาพสูงโดยอิงจาก LLM ที่พวกเขาฝึกฝน อินเทอร์เฟซแชทบอทที่มี AI เจนเนอเรชั่นจะสามารถจดจำ สรุป แปล คาดการณ์ และสร้างเนื้อหาเพื่อตอบสนองต่อคำถามของผู้ใช้โดยไม่จำเป็นต้องมีการโต้ตอบกับมนุษย์ [3]

2.3 ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

2.3.1 ปัญญาประดิษฐ์และโมเดลภาษาขนาดใหญ่ (Artificial Intelligence & LLM)

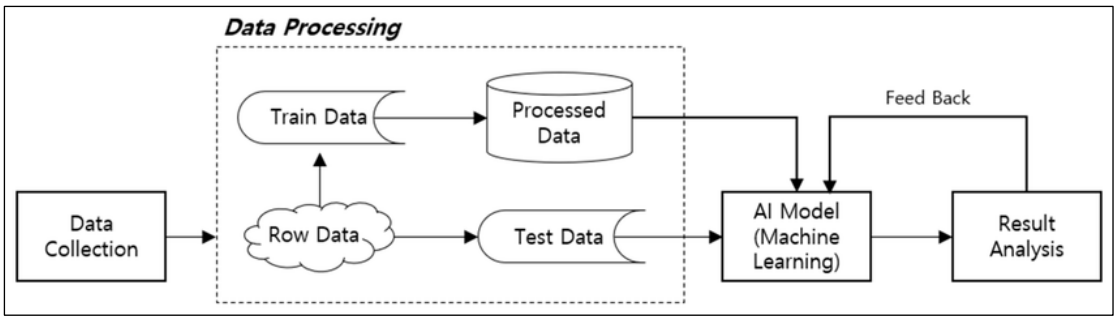
(1) ปัญญาประดิษฐ์ (Artificial Intelligence)

ปัญญาประดิษฐ์ หรือ Artificial Intelligence (AI) คือศาสตร์ทางด้านวิทยาศาสตร์และวิศวกรรมศาสตร์ในการสร้างความฉลาดให้กับเครื่องจักรกลหรือโปรแกรมคอมพิวเตอร์ โดยมีวัตถุประสงค์หลักเพื่อให้เทคโนโลยีเหล่านี้สามารถ คิด วิเคราะห์ และเลียนแบบพฤติกรรมของมนุษย์ เพื่อใช้ในการตัดสินใจและแก้ปัญหาได้เสมือนที่มนุษย์ทำ หากพิจารณาตามรากศัพท์ คำว่า Artificial หมายถึงสิ่งที่สร้างขึ้นหรือสังเคราะห์ขึ้นโดยมนุษย์และไม่มีชีวิต ส่วน Intelligence หมายถึงกระบวนการคิดประมวลผลที่นำไปสู่ความสำเร็จหรือความฉลาดที่พบได้ทั้งในมนุษย์และสัตว์ ปัญญาประดิษฐ์จึงเป็นศาสตร์ที่เกี่ยวข้องกับการรวบรวมข้อมูล การประมวลผลสารสนเทศด้วยสัญลักษณ์ และการนำเสนอองค์ความรู้โดยอาจอาศัยหรือไม่ต้องอาศัยกฎเกณฑ์ที่ตายตัวก็ได้ ทั้งนี้ความสามารถของปัญญาประดิษฐ์สามารถจำแนกออกเป็น 3 ระดับ ได้แก่ ปัญญาประดิษฐ์ทั่วไป (General AI) ที่มีความสามารถระดับเดียวกับมนุษย์ ปัญญาประดิษฐ์เชิงแคบ (Narrow AI) ที่เชี่ยวชาญเฉพาะทางมากกว่ามนุษย์ เช่น ระบบช่วยผ่าตัด และ ปัญญาประดิษฐ์แบบเข้ม (Strong AI) ที่มีความฉลาดเหนือกว่ามนุษย์ในหลากหลายด้าน

ในเชิงโครงสร้างการทำงาน ระบบปัญญาประดิษฐ์ถูกพัฒนาขึ้นใน 2 รูปแบบหลัก คือ ระบบการคิดคล้ายมนุษย์ ที่เน้นการเลียนแบบกลไกทางสติปัญญา การตัดสินใจ และการ

เรียนรู้บนพื้นฐานของเหตุและผล และ ระบบที่กระทำเหมือนมนุษย์ ที่เน้นการเลียนแบบการแสดงออก พฤติกรรม การสื่อสารด้วยภาษา และมีประสาทสัมผัสที่คล้ายคลึงกับมนุษย์ โดยมีคุณลักษณะเด่นที่ขับเคลื่อนระบบอัจฉริยะนี้หลายประการ เช่น จักรกลการเรียนรู้ (Machine Learning) ที่ช่วยให้ระบบเรียนรู้จากข้อมูลมหาศาลได้เองเสมือนเป็นสมอง การประมวลผลภาษาธรรมชาติ (NLP) ที่ทำให้คอมพิวเตอร์เข้าใจภาษามนุษย์ ระบบผู้เชี่ยวชาญ (Expert System) ที่ใช้ฐานความรู้ในการวิเคราะห์งานเฉพาะทาง ตลอดจนระบบทรรศนะ (Vision System) และหุ่นยนต์ (Robotic) ที่เพิ่มความแม่นยำในการทำงานแทนมนุษย์

เมื่อนำปัญญาประดิษฐ์มาประยุกต์ใช้ในบริบทของ ระบบนิเวศการเรียนรู้ดิจิทัล เทคโนโลยีนี้จะเข้ามามีบทบาทสำคัญในการส่งเสริมการเรียนรู้อย่างชาญฉลาดผ่าน 4 บทบาทหลัก คือ การเป็นผู้สร้างสรรค์อัจฉริยะ ที่ผลิตเนื้อหาและสื่อการสอนที่เหมาะสมกับผู้เรียน การเป็นผู้สอนเสมือนจริง ที่คอยตอบข้อสงสัยแทนผู้สอนได้ตลอดเวลา การเป็นติวเตอร์อัจฉริยะ ที่ช่วยสอนเสริมและวิเคราะห์จุดแข็งจุดอ่อนของผู้เรียนเป็นรายบุคคล และการเป็นผู้ดูแลระบบอัจฉริยะ ที่ช่วยจัดการงานธุรการ เช่น การตรวจคะแนนและประเมินผลอัตโนมัติ ซึ่งการทำงานเหล่านี้ช่วยลดข้อจำกัดเรื่องเวลาและสถานที่ ทำให้ผู้เรียนสามารถแสวงหาความรู้ได้ทั้งในห้องเรียน นอกห้องเรียน และที่บ้านอย่างมีประสิทธิภาพ ส่งผลให้ปัญญาประดิษฐ์กลายเป็นเครื่องมือสำคัญในการยกระดับศักยภาพทรัพยากรมนุษย์ตามยุทธศาสตร์การพัฒนาประเทศในยุคดิจิทัล [4]



ภาพที่ 2-1 แผนผังขั้นตอนการทำงานของระบบปัญญาประดิษฐ์ (AI)

ที่มา: https://www.researchgate.net/figure/Artificial-intelligence-AI-machine-learning-flow_fig1_342799028

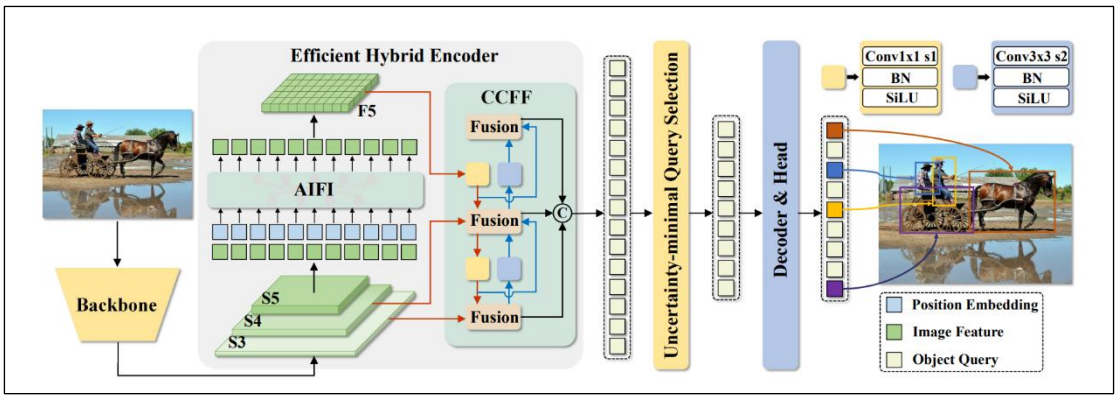
(2) โมเดลภาษาขนาดใหญ่ (Large Language Models)

โมเดลภาษาขนาดใหญ่ หรือ Large Language Models (LLMs) คือโมเดลภาษาที่ผ่านการฝึกฝนล่วงหน้า (Pre-trained Language Models - PLMs) ซึ่งได้รับการขยายขนาดของพารามิเตอร์ขึ้นอย่างมหาศาล โดยทั่วไปมักมีจำนวนพารามิเตอร์ตั้งแต่ระดับหมื่นล้านไปจนถึงหลายแสนล้านรายการขึ้นไป ระบบเหล่านี้ถูกพัฒนาขึ้นเพื่อเป้าหมายในการทำให้เครื่องจักรมีความฉลาดทางภาษาเทียบเคียงกับมนุษย์ ซึ่งมีรากฐานมาจากการวิจัยที่ยาวนานหลายทศวรรษ โดยวิวัฒนาการมาจากโมเดลภาษาเชิงสถิติ (Statistical Language Models) ในทศวรรษที่ 1990 และ

พัฒนาเข้าสู่ยุคโมเดลภาษาแบบโครงข่ายประสาทเทียม (Neural Language Models) ในช่วงปี 2003 ที่เริ่มใช้เวกเตอร์แทนความหมายของคำ. จุดเปลี่ยนสำคัญเกิดขึ้นเมื่อมีการนำสถาปัตยกรรม Transformer มาใช้ ซึ่งอาศัยกลไกการให้ความสำคัญ (Self-attention mechanism) ทำให้โมเดลสามารถเข้าใจความสัมพันธ์เชิงบริบทภายในประโยคที่ซับซ้อนได้อย่างมีประสิทธิภาพและประมวลผลข้อมูลมหาศาลได้รวดเร็วขึ้น คุณลักษณะสำคัญที่ทำให้ LLMs แตกต่างจากโมเดลภาษาขนาดเล็กคือการปฏิบัติตาม กฎการขยายขนาด (Scaling Laws) ซึ่งระบุว่าประสิทธิภาพของโมเดลจะเพิ่มขึ้นอย่างต่อเนื่องตามการเพิ่มขึ้นของพารามิเตอร์ ปริมาณข้อมูลที่ใช้ฝึกฝน และทรัพยากรการคำนวณ. เมื่อโมเดลถูกขยายขนาดจนถึงระดับหนึ่งจะเกิดลักษณะที่เรียกว่า "ความสามารถที่งอกเงย" (Emergent Abilities) ซึ่งเป็นความสามารถพิเศษที่ไม่อาจคาดการณ์ได้จากโมเดลขนาดเล็ก เช่น การเรียนรู้ในบริบท (In-context learning) ที่ช่วยให้โมเดลทำงานใหม่ๆ ได้เพียงแค่ได้รับคำสั่งหรือตัวอย่างโดยไม่ต้องปรับแก้พารามิเตอร์, การปฏิบัติตามคำสั่ง (Instruction following) และ การให้เหตุผลเป็นลำดับขั้นตอน (Step-by-step reasoning) ผ่านเทคนิค Chain-of-Thought (CoT) [5]

2.3.2 RT-DETR (Real-Time DEtection TRansformer)

RT-DETR (Real-Time DEtection TRansformer) คือสถาปัตยกรรมตัวตรวจจับวัตถุแบบ end-to-end ตัวแรกที่สามารถทำงานได้ในแบบเรียลไทม์ (Real-time) โดยมีจุดประสงค์หลักเพื่อแก้ไขข้อจำกัดของตัวตรวจจับวัตถุในตระกูล YOLO ที่มักได้รับผลกระทบในด้านความเร็วและความแม่นยำจากกระบวนการ Non-Maximum Suppression (NMS) ซึ่งเป็นขั้นตอนการประมวลผลภายหลัง (Post-processing) ที่ซับซ้อนและมีไฮเปอร์พารามิเตอร์ที่ควบคุมได้ยาก ในขณะเดียวกัน RT-DETR ยังถูกออกแบบมาเพื่อลดภาระการคำนวณที่สูงเกินไปของโมเดลตระกูล DETR รุ่นก่อนหน้า ซึ่งมักทำให้ไม่สามารถนำไปใช้งานในสถานการณ์ที่ต้องการการตอบสนองแบบทันทีได้ โครงสร้างภายในของ RT-DETR ประกอบด้วยส่วนประกอบสำคัญสองส่วน ได้แก่ Efficient Hybrid Encoder ซึ่งทำหน้าที่ประมวลผลฟีเจอร์หลายสเกล (Multi-scale features) ได้อย่างรวดเร็วผ่านการแยกส่วนปฏิสัมพันธ์ภายในสเกลเดียวกัน (Intra-scale interaction) และการหลอมรวมฟีเจอร์ข้ามสเกล (Cross-scale fusion) โดยใช้โมดูล AIFI (Attention-based Intra-scale Feature Interaction) และ CCFF (CNN-based Cross-scale Feature Fusion) เพื่อลดความซ้ำซ้อนในการคำนวณ และส่วนที่สองคือ Uncertainty-minimal Query Selection ซึ่งเป็นกลไกการเลือก Query เริ่มต้นที่มีคุณภาพสูงให้กับตัว Decoder โดยพิจารณาจากความไม่แน่นอน (Uncertainty) ที่รวมทั้งความเชื่อมั่นในการจำแนกประเภทและความแม่นยำในการระบุตำแหน่งเข้าด้วยกัน ทำให้โมเดลมีความแม่นยำสูงขึ้น [6]

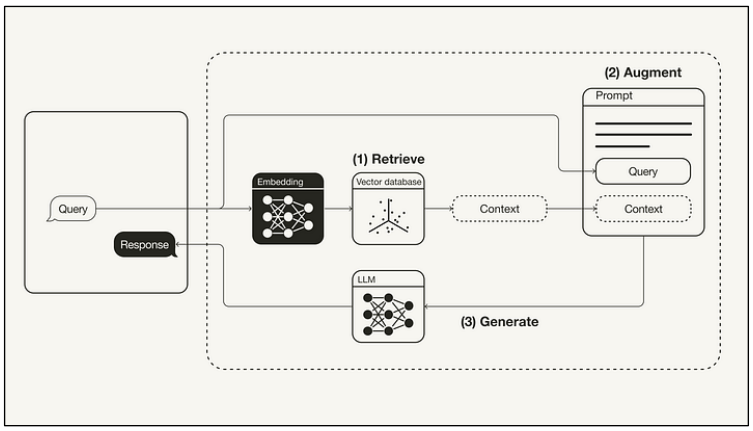


ภาพที่ 2-2 แผนผังโครงสร้างสถาปัตยกรรมของ RT-DETR (Real-Time DEtection TRansformer)

ที่มา: https://arxiv.org/pdf/2304.08069

2.3.3 เทคนิค Retrieval-Augmented Generation (RAG)

เทคนิค Retrieval-Augmented Generation (RAG) คือสถาปัตยกรรมทางเทคโนโลยีที่บูรณาการประสิทธิภาพของการดึงข้อมูล (Information Retrieval) เข้ากับความสามารถในการสร้างภาษาธรรมชาติของโมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) เพื่อเพิ่มขีดความสามารถในการตอบคำถามได้อย่างแม่นยำและสอดคล้องกับบริบทเฉพาะ, กระบวนการทำงานของ RAG สามารถแบ่งออกเป็นสี่ระยะหลักที่ทำงานประสานกันอย่างเป็นระบบ เริ่มต้นจากขั้นตอนการนำเข้าข้อมูล (Ingestion) ซึ่งเป็นการจัดการเอกสารต้นทางโดยการแบ่งย่อยเนื้อหาออกเป็นส่วนๆ (Chunks) ในขนาดที่เหมาะสม เช่น การวิเคราะห์โครงสร้างไฟล์ PDF เพื่อให้คงความหมายเชิงบริบทไว้โดยไม่สร้างสัญญาณรบกวนที่มากเกินไป จากนั้นชิ้นข้อมูลเหล่านี้จะถูกแปลงเป็นเวกเตอร์ที่มีมิติสูง (Embeddings) เพื่อแสดงคุณลักษณะเชิงความหมายและถูกจัดเก็บไว้ในฐานข้อมูลเวกเตอร์ (Vector Store) เพื่อใช้ในการค้นหาที่เปี่ยมประสิทธิภาพ เมื่อมีการส่งคำถาม (Query) เข้าสู่ระบบ จะเข้าสู่ขั้นตอนการดึงข้อมูล (Retrieval) โดยคำถามจะถูกแปลงเป็นเวกเตอร์เพื่อทำการค้นหาความคล้ายคลึง (Similarity Search) ในฐานข้อมูลเวกเตอร์ เพื่อระบุและคัดเลือกชิ้นข้อมูลที่มีความเกี่ยวข้องมากที่สุดจำนวน k ชุด (Top k chunks) ซึ่งขั้นตอนนี้ช่วยจำกัดขอบเขตข้อมูลให้เหลือเฉพาะเนื้อหาที่จำเป็นต่อการสร้างคำตอบ ข้อมูลที่ดึงมาได้จะถูกนำไปรวมกับคำถามเดิมเพื่อเข้าสู่ขั้นตอนการสร้างคำตอบ (Generation) โดยใช้โมเดลภาษาขนาดใหญ่ เช่น GPT-4-Turbo ทำหน้าที่สังเคราะห์และเรียบเรียงข้อมูลจากบริบทที่ได้รับให้เป็นคำตอบที่อ่านง่ายและเป็นธรรมชาติ, ในขั้นตอนนี้ การออกแบบคำสั่ง (Prompt) มีบทบาทสำคัญอย่างยิ่งในการกำหนดให้โมเดลตอบคำถามโดยอ้างอิงจากบริบทที่ดึงมาได้เท่านั้น และให้ระบุว่าไม่ทราบหากไม่พบคำตอบในข้อมูลดังกล่าว เพื่อป้องกันการสร้างข้อมูลที่เป็นเท็จหรือการหลอนของโมเดล (Hallucination) [7]



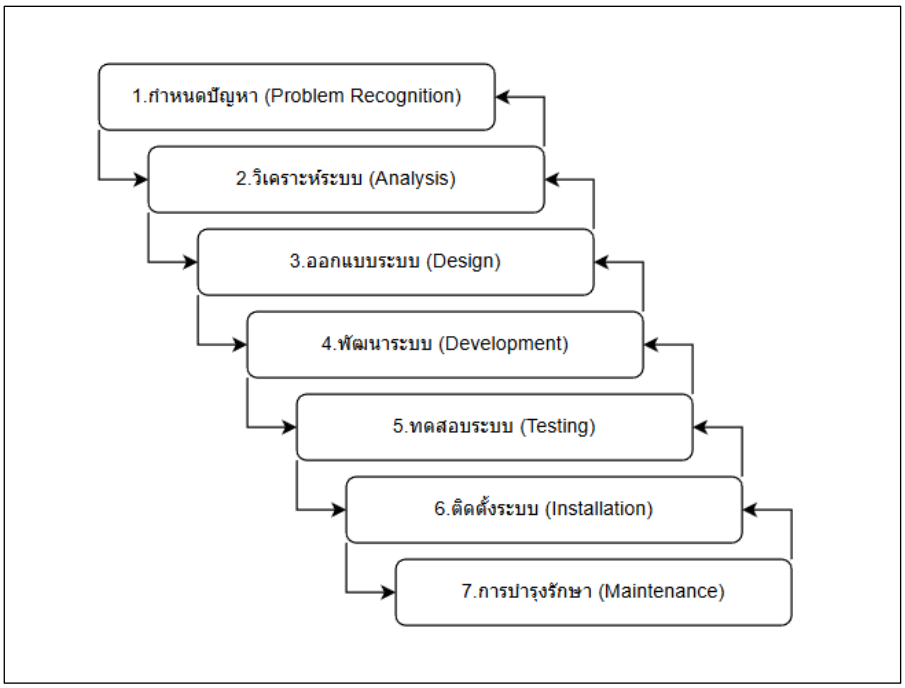
ภาพที่ 2-3 แผนผังกระบวนการทำงานของ Retrieval-Augmented Generation (RAG)
ที่มา: https://www.leoniemonigatti.com/blog/retrieval-augmented-generation-langchain.html

2.3.4 ระบบฐานข้อมูลเวกเตอร์ (Vector Database)

ระบบจัดการฐานข้อมูลเวกเตอร์ (Vector Database Management System หรือ VDBMS) คือระบบที่ออกแบบมาเพื่อจัดการข้อมูลที่ไม่มีโครงสร้าง (Unstructured data) เช่น รูปภาพ เอกสาร หรือเสียง ซึ่งข้อมูลเหล่านี้ไม่สามารถจัดเก็บหรือค้นหาได้อย่างมีประสิทธิภาพในฐานข้อมูลแบบดั้งเดิมที่มีโครงสร้างแบบตารางตายตัว โดยระบบนี้จะใช้สิ่งที่เรียกว่า "เวกเตอร์คุณลักษณะ" (Feature Vectors) หรือ "เวกเตอร์ฝังตัว" (Embeddings) ในการเป็นตัวแทนของข้อมูลเหล่านั้น โดยทั่วไปจะแบ่งออกเป็น 2 ส่วนหลัก คือ ตัวประมวลผลคำสั่ง (Query Processor) ที่ทำหน้าที่ปรับปรุงชุดคำสั่งและบริหารการดำเนินการ และ ตัวจัดการส่วนจัดเก็บ (Storage Manager) ที่ทำหน้าที่ดูแลดัชนี (Search indexes) และการจัดเก็บเวกเตอร์ในเชิงกายภาพ ในฐานข้อมูลปกติการเปรียบเทียบค่ามักใช้เวลาคงที่ (O(1)) แต่การเปรียบเทียบเวกเตอร์มีค่าใช้จ่ายสูงกว่ามาก (O(D) ตามจำนวนมิติ) และเวกเตอร์มักมีขนาดใหญ่จนทำให้การดึงข้อมูลจากดิสก์มีราคาสูง นอกจากนี้เวกเตอร์ยังไม่มีการเรียงลำดับตามธรรมชาติ ทำให้การออกแบบดัชนีเป็นเรื่องที่ท้าทาย โดยแยกเป็นประเภทของระบบได้ดังนี้ 1) Native Systems: ระบบที่ถูกสร้างขึ้นเพื่อจัดการเวกเตอร์โดยเฉพาะ เช่น Milvus, Pinecone และ Vearch ซึ่งมักจะมีประสิทธิภาพสูงในงานเฉพาะทาง 2) Extended Systems: การเพิ่มความสามารถด้านเวกเตอร์เข้าไปในฐานข้อมูลเดิมที่มีอยู่ เช่น pgvector (สำหรับ PostgreSQL) หรือการเพิ่มในระบบ NoSQL อย่าง Redis และ Elasticsearch หากเปรียบเทียบให้เห็นภาพ ฐานข้อมูลทั่วไปเปรียบเสมือนตู้เก็บเอกสารที่เรียงตามลำดับตัวอักษร ซึ่งเราหาของได้ง่ายถ้าสะกดชื่อถูก แต่ ฐานข้อมูลเวกเตอร์เปรียบเสมือนภัณฑารักษ์ในหอศิลป์ ที่ไม่ได้จำว่ารูปแต่ละรูปชื่ออะไร แต่อธิบายได้ว่ารูปไหนมี "อารมณ์" หรือ "สไตล์" คล้ายกับรูปที่เรากำลังมองหาอยู่ แม้ว่ารูปนั้นจะไม่มีคำบรรยายกำกับไว้เลยก็ตาม [8]

2.3.5 วงจรการพัฒนาระบบ (SDLC)

วงจรการพัฒนาระบบ (System Development Life Cycle :SDLC) ระบบสารสนเทศทั้งหลายมีวงจรชีวิตที่เหมือนกันตั้งแต่เกิดจนตายวงจรนี้จะเป็นขั้นตอน ที่เป็นลำดับตั้งแต่ต้นจนเสร็จเรียบร้อย เป็นระบบที่ใช้งานได้ ซึ่งนักวิเคราะห์ระบบต้องทำความเข้าใจให้ดีว่าในแต่ละขั้นตอนจะต้องทำอะไร และทำอย่างไร ขั้นตอนการพัฒนาระบบมีอยู่ด้วยกัน 7 ขั้น ด้วยกัน ดังภาพที่ 2-4



ภาพที่ 2-4 วงจรพัฒนาระบบ (SDLC)

(1) การค้นหาและเลือกสรรโครงการ (Project Identification and Selection) เป็นขั้นตอน ในการค้นหาโครงการพัฒนาระบบที่เหมาะสมกับสถานการณ์ปัจจุบันของบริษัทสามารถแก้ปัญหาที่เกิดขึ้น และให้ผลประโยชน์กับบริษัทมากที่สุด โดยใช้ตารางเมตริก (Matrix Table) เป็นเครื่องมือประกอบการพิจารณาซึ่งเป็นขั้นตอนที่ได้ดำเนินการผ่านไปแล้วในเบื้องต้น

(2) การเริ่มต้นและวางแผนโครงการ (Project Initiating and Planning System Development) เป็นขั้นตอนในการเริ่มต้นจัดทำโครงการด้วยการจัดตั้งทีมงาน กำหนดตำแหน่งหน้าที่ให้กับทีมงานแต่ละคนอย่างชัดเจนเพื่อร่วมกันสร้างแนวทางเลือกในการนำระบบใหม่มาใช้งานและเลือกทางเลือกที่ดีที่สุดจากนั้นจะร่วมกันวางแผนจัดทำโครงการกำหนด ระยะเวลาในการดำเนินโครงการศึกษาความเป็นไปได้ของโครงการและประมาณการต้นทุน และกำไรที่จะได้รับจากการลงทุนในโครงการพัฒนาระบบ เพื่อนำเสนอต่อผู้จัดการเพื่อพิจารณาอนุมัติดำเนินการในขั้นตอนต่อไป โดยในขณะที่นำเสนอโครงการอยู่นี้ถือเป็นการดำเนินงานในขั้นตอนที่ 2 ซึ่งใช้เทคนิคในการเก็บรวบรวม

ข้อเท็จจริงด้วยการสัมภาษณ์ (Interviewing) การออกแบบสอบถาม (Questionnaires) รวมทั้งพิจารณาจากเอกสารการทำงานรายงานและแบบฟอร์มต่างๆ

(3) การวิเคราะห์ (System Analysis) เป็นขั้นตอนในการศึกษาและวิเคราะห์ถึงขั้นตอน การดำเนินงานของระบบเดิม ซึ่งการที่จะสามารถดำเนินการในขั้นตอนนี้ได้จะต้องผ่านการอนุมัติในขั้นตอนที่ 2 ใน การนำเสนอโครงการหลังจากนั้นจะรวบรวมความต้องการในระบบใหม่ จากผู้ใช้ระบบแล้วนำมาศึกษาและวิเคราะห์ความต้องการเหล่านั้นด้วย การใช้เครื่องมือชนิดต่าง ๆ

(4) การออกแบบเชิงตรรกะ (Logical Design) เป็นขั้นตอนในการออกแบบลักษณะการทำงานของระบบตามทางเลือกที่ได้จากการเลือกไว้จากขั้นตอน การวิเคราะห์ระบบโดยการออกแบบในเชิงตรรกะนี้ยังไม่ได้มีการระบุถึงคุณลักษณะ ของอุปกรณ์ที่จะนำมาใช้ เพียงแต่กำหนดถึงลักษณะของรูปแบบรายงานที่เกิดจากการทำงานของระบบ ลักษณะของการนำข้อมูลเข้าสู่ระบบ และผลลัพธ์ที่ได้จากระบบ ซึ่งจะเลือกใช้การนำเสนอรูปแบบของรายงาน และลักษณะของจอภาพของระบบ จะทำให้สามารถเข้าใจขั้นตอนการทำงานของระบบได้ชัดเจนขึ้น

(4) การออกแบบเชิงตรรกะ (Logical Design) เป็นขั้นตอนในการออกแบบลักษณะการทำงานของระบบตามทางเลือกที่ได้จากการเลือกไว้จากขั้นตอน การวิเคราะห์ระบบโดยการออกแบบในเชิงตรรกะนี้ยังไม่ได้มีการระบุถึงคุณลักษณะ ของอุปกรณ์ที่จะนำมาใช้ เพียงแต่กำหนดถึงลักษณะของรูปแบบรายงานที่เกิดจากการทำงานของระบบ ลักษณะของการนำข้อมูลเข้าสู่ระบบ และผลลัพธ์ที่ได้จากระบบ ซึ่งจะเลือกใช้การนำเสนอรูปแบบของรายงาน และลักษณะของจอภาพของระบบ จะทำให้สามารถเข้าใจขั้นตอนการทำงานของระบบได้ชัดเจนขึ้น

(5) การออกแบบเชิงกายภาพ (Physical Design) เป็นขั้นตอนที่ระบุถึงลักษณะการทำงานของระบบทางกายภาพหรือทางเทคนิค โดยระบุถึงคุณลักษณะของอุปกรณ์ที่จะนำมาใช้ เทคโนโลยีโปรแกรมภาษาที่จะนำมาทำการเขียนโปรแกรม ฐานข้อมูลของการออกแบบเครือข่ายที่เหมาะสมกับระบบ สิ่งที่ได้จากขั้นตอนการออกแบบทางกายภาพนี้จะเป็นข้อมูลของการออกแบบเพื่อส่งมอบให้กับโปรแกรมเมอร์เพื่อใช้เขียนโปรแกรมตามลักษณะการทำงานของระบบที่ได้ออกแบบและกำหนดไว้

(6) การพัฒนาและติดตั้งระบบ (System Implementation) เป็นขั้นตอนในการนำข้อมูลเฉพาะ ของการออกแบบมาทำการเขียนโปรแกรมเพื่อให้เป็นไปตามคุณลักษณะและรูปแบบต่างๆ ที่ได้กำหนดไว้ หลังจากเขียนโปรแกรมเรียบร้อยแล้ว จะต้องทำการทดสอบโปรแกรมตรวจสอบหาข้อผิดพลาดของโปรแกรมที่พัฒนาขึ้นมา และสุดท้ายคือการติดตั้งระบบ โดยทำการติดตั้งตัวโปรแกรมติดตั้งอุปกรณ์ พร้อมทั้งจัดทำคู่มือและจัดเตรียมหลักสูตรฝึกอบรมผู้ใช้งานที่เกี่ยวข้องเพื่อให้ระบบใหม่สามารถใช้งานได้

(7) การซ่อมบำรุงระบบ (System Maintenance) หลังจากระบบงานที่พัฒนาขึ้นใหม่ได้ถูกนำไปใช้งานเป็นที่เรียบร้อยแล้ว ขั้นตอนการบำรุงรักษาจึงเกิดขึ้น ทั้งนี้ข้อบกพร่องในด้านการทำงานของโปรแกรมอาจเพิ่งค้นพบได้ ซึ่งจะต้องดำเนินการแก้ไขให้ถูกต้องรวมถึงกรณีที่ข้อมูลที่จัดเก็บมีปริมาณที่มากขึ้นต้องวางแผนการรองรับเหตุการณ์นี้ด้วยนอกจากนี้งานบำรุงรักษายังเกี่ยวข้องกับการเขียนโปรแกรมเพิ่มเติมกรณีที่ผู้ใช้มีความต้องการเพิ่มขึ้น [9]

2.4 เครื่องมือที่ใช้ในการพัฒนา

2.4.1 LINE Official Account & Messaging API

(1) LINE Official Account

LINE Official Account (LINE OA) คือ บัญชี LINE สำหรับธุรกิจหรือองค์กรขนาดใหญ่ (รวมถึงร้านค้าและผู้ใช้งานทั่วไป) ที่ถูกออกแบบมาเพื่อช่วยให้เจ้าของบัญชีสามารถสื่อสารและส่งข้อมูลข่าวสารไปยังลูกค้าหรือผู้ที่ติดตามได้สะดวกและมีประสิทธิภาพมากขึ้น โดยแบ่งประเภทของบัญชีดังนี้ 1) โล่สีเขียว (Premium Account): บัญชีสำหรับธุรกิจหรือองค์กรขนาดใหญ่ 2) โล่สีน้ำเงิน (Verified Account): บัญชีที่ได้รับการรับรองจาก LINE ช่วยให้ลูกค้าค้นหาผ่าน LINE Chat ได้ง่ายขึ้นและสามารถสร้างโปสเตอร์โปรโมทได้ 3) โล่สีเทา (Unverified Account): บัญชีทั่วไปที่ยังไม่ได้รับการรับรอง แต่สามารถขอรับรองบัญชีภายหลังได้ มีคุณสมบัติและเครื่องมือเด่นๆคือ 1) การบรอดแคสต์ (Broadcast): ความสามารถในการส่งข้อความ รูปภาพ วิดีโอ หรือโปรโมชันต่างๆ ให้กับลูกค้าที่เป็นเพื่อนกับบัญชีของเราได้พร้อมกันในครั้งเดียว หรือจะเลือกส่งเฉพาะกลุ่มเป้าหมายตามเพศ อายุ หรือพื้นที่ก็ได้ 2) ริชเมนู (Rich Menu): เมนูลัดที่ปรากฏอยู่ด้านล่างของหน้าจอแชท ช่วยให้ลูกค้ากดเข้าถึงข้อมูล ลิงก์ หรือคูปองที่ต้องการได้รวดเร็วและสะดวก 3) ข้อความตอบกลับอัตโนมัติ: สามารถตั้งค่าข้อความทักทายเพื่อนใหม่ หรือตั้งค่าการตอบกลับอัตโนมัติ (AI Chatbot) เพื่อดูแลลูกค้าได้ตลอดเวลา 4) คอนเทนต์รูปแบบพิเศษ: เช่น ริชเมสเสจ (Rich Message) ที่เป็นรูปภาพขนาดใหญ่เต็มหน้าจอแชท หรือ การ์ดเมสเสจ (Card-based Message) ที่แสดงเนื้อหาแบบภาพสไลด์ ช่วยให้การนำเสนอสินค้าน่าสนใจยิ่งขึ้น [10]

(2) Messaging API

Messaging API คือตัวกลาง (Mediator) ที่ทำหน้าที่เชื่อมต่อระหว่าง Server ของผู้พัฒนากับ LINE Official Account เพื่อให้นักพัฒนาสามารถเขียนโปรแกรมสร้างบริการต่าง ๆ ตามที่ต้องการได้ โดยเน้นการสื่อสารและโต้ตอบกับผู้ใช้งานในรูปแบบของ Chatbot โดยมีฟีเจอร์หลักในการสื่อสารคือ 1) Reply messages: เป็นการโต้ตอบในลักษณะ Two-way communication โดยที่ผู้ใช้จะเป็นฝ่ายเริ่มส่งข้อความหรือเพิ่ม Chatbot เป็นเพื่อนก่อน แล้วตัวระบบจะทำการตอบกลับข้อความนั้นไปหาผู้ใช้โดยอัตโนมัติ 2) Flex Message: ระบบที่ช่วยให้ผู้พัฒนาสามารถออกแบบ

การแสดงผลข้อความได้อย่างอิสระ ฉีกกฎการแสดงผลข้อความแบบเดิม ๆ ใน LINE เพื่อให้ตรงกับอัตลักษณ์ของแบรนด์หรือความต้องการเฉพาะด้าน 3) การดึงข้อมูลโปรไฟล์ของผู้ใช้: นักพัฒนาสามารถเก็บข้อมูลของผู้ใช้งานผ่าน API ได้ เช่น userId, ชื่อ (displayName), ข้อความสถานะ, รูปโปรไฟล์ รวมถึงอีเมลและภาษาของอุปกรณ์ที่ใช้งาน [11]

2.4.2 n8n (Workflow Automation)

n8n (Workflow Automation) คือ ครื่องมือสำหรับสร้างการทำงานอัตโนมัติหรือ Workflow Automation ที่ได้รับการออกแบบมาเพื่อทำหน้าที่เป็นตัวกลางในการเชื่อมต่อระหว่างแอปพลิเคชันต่าง ๆ ผ่าน API โดยใช้แนวคิดแบบ No-code ซึ่งช่วยให้ผู้ใช้งานที่ไม่มีทักษะด้านการเขียนโปรแกรมหรือไม่ได้เป็นนักพัฒนาซอฟต์แวร์ สามารถออกแบบและสร้างกระบวนการทำงานที่ซับซ้อนได้ด้วยตนเอง แพลตฟอร์มนี้มีความโดดเด่นในด้านความยืดหยุ่นของการติดตั้ง โดยรองรับทั้งการใช้งานผ่านระบบคลาวด์บนเว็บไซต์ n8n.com และการใช้งานในรูปแบบ Self-host บนเครื่องคอมพิวเตอร์ส่วนบุคคลหรือเซิร์ฟเวอร์ขององค์กรผ่านเครื่องมืออย่าง npm และ Docker ซึ่งการเลือกใช้รูปแบบ Self-host นั้นจะช่วยให้ผู้ใช้สามารถบริหารจัดการระบบได้โดยไม่มีค่าใช้จ่ายเพิ่มเติมในส่วนของตัวแพลตฟอร์ม [12]

2.4.3 Pinecone Vector Database

Pinecone คือแพลตฟอร์มฐานข้อมูลแบบ Vector ที่ออกแบบมาเพื่อเป็นโครงสร้างพื้นฐานสำคัญในการพัฒนาแอปพลิเคชันปัญญาประดิษฐ์ (AI) ยุคใหม่ โดยมุ่งเน้นที่ความแม่นยำ ความปลอดภัย และความสามารถในการขยายตัวของระบบ หัวใจหลักของ Pinecone คือการจัดการข้อมูลในรูปแบบของ Vector หรือชุดตัวเลขที่ใช้แทนค่าความหมายของข้อมูลเชิงลึก เช่น ข้อความ รูปภาพ หรือเสียง เพื่อให้ระบบ AI สามารถทำความเข้าใจและประมวลผลข้อมูลเหล่านั้นได้ในลักษณะที่ใกล้เคียงกับความเข้าใจของมนุษย์ ฐานข้อมูลชนิดนี้จะทำหน้าที่จัดเก็บและค้นหา Vector เหล่านี้ด้วยความเร็วและประสิทธิภาพสูง ซึ่งจากประสบการณ์การใช้งานจริงพบว่า Pinecone สามารถช่วยลดระยะเวลาในการพัฒนา AI ลงได้มาก โดยเฉพาะในโครงการที่ต้องเผชิญกับชุดข้อมูลขนาดใหญ่ (Big Data) ในด้านคุณสมบัติทางเทคนิค Pinecone ถูกออกแบบมาให้มีความยืดหยุ่นสูง (Scalability) ซึ่งผู้พัฒนาสามารถเริ่มต้นใช้งานได้โดยง่ายและสามารถขยายขีดความสามารถของระบบเพื่อรองรับข้อมูลจำนวนมหาศาลได้อย่างไม่มีขีดจำกัด จึงเหมาะสมกับทั้งธุรกิจระดับสตาร์ทอัพและองค์กรขนาดใหญ่ นอกจากนี้ ระบบยังรองรับการทำงานร่วมกับโมเดล AI ที่หลากหลาย ไม่ว่าจะเป็นโมเดลจากผู้ให้บริการชั้นนำอย่าง OpenAI, Google หรือแม้แต่โมเดลที่ผู้พัฒนาปรับแต่งขึ้นเอง (Custom Models) พร้อมกันนี้ Pinecone ยังให้ความสำคัญกับมาตรฐานความปลอดภัยของข้อมูลในระดับองค์กร โดยรองรับมาตรฐานสำคัญอย่าง SOC2 Type II และ HIPAA รวมถึงมีระบบเข้ารหัสข้อมูลเพื่อป้องกันความเป็นส่วนตัวและความปลอดภัยของข้อมูลอย่างเข้มงวด [13]

2.4.4 Google Gemini API

Google Gemini API คืออินเทอร์เฟซโปรแกรมประยุกต์ที่ช่วยให้นักพัฒนาสามารถเข้าถึงและผสานรวมความสามารถของโมเดลปัญญาประดิษฐ์ที่มีประสิทธิภาพสูงสุดของ Google ซึ่งถูกพัฒนาขึ้นเพื่อทดแทนและต่อยอดจากโมเดล Bard เดิม โดยคุณลักษณะเด่นที่สำคัญที่สุดคือการเป็นโมเดลแบบมัลติโมดอล (Multimodal) มาตั้งแต่เริ่มต้น ซึ่งหมายถึงความสามารถในการประมวลผลและทำความเข้าใจข้อมูลหลากหลายรูปแบบพร้อมกัน ไม่ว่าจะเป็นข้อความ รหัสโปรแกรม (Code) เสียง รูปภาพ และวิดีโอ การพัฒนา Gemini API ภายใต้เวอร์ชัน 1.0 นั้น Google ได้นำเสนอโมเดลที่แตกต่างกันสามขนาดเพื่อตอบสนองความต้องการที่หลากหลาย ได้แก่ Gemini Ultra ซึ่งเป็นรุ่นที่มีความสามารถสูงสุดสำหรับการทำงานที่ซับซ้อนและการให้เหตุผลระดับสูง Gemini Pro ที่ปรับสมดุลระหว่างประสิทธิภาพกับต้นทุนและความเร็วในการตอบสนอง และ Gemini Nano ที่ถูกออกแบบมาเพื่อการทำงานบนอุปกรณ์พกพาที่มีข้อจำกัดด้านหน่วยความจำ ด้านประสิทธิภาพ Gemini API มีความสามารถในการให้เหตุผลที่ซับซ้อน (Complex Reasoning) ซึ่งช่วยให้โมเดลสามารถวิเคราะห์และอนุมานความหมายที่ซ่อนอยู่ท่ามกลางข้อมูลมหาศาล รวมถึงการดึงข้อมูลเฉพาะเจาะจงจากเอกสารจำนวนมากตามเกณฑ์ที่ผู้ใช้กำหนด นอกจากนี้ยังมีทักษะด้านการเขียนโค้ดขั้นสูง โดยสามารถทำความเข้าใจ อธิบาย และสร้างรหัสโปรแกรมในภาษาที่เป็นที่นิยม เช่น Python, Java, C++ และ Go ได้อย่างแม่นยำ [14]

2.4.5 Flowchart

Flowchart (โฟลวชาร์ต) หรือผังงาน คือ แผนภาพที่มีการใช้สัญลักษณ์รูปภาพและลูกศรที่ แสดงให้เห็นถึงขั้นตอนการทำงานของระบบทีละขั้นตอนอย่างชัดเจน โดยแต่ละสัญลักษณ์ในแผนภาพ Flowchart นั้นจะหมายถึงการทำงานในหนึ่งขั้นตอน สัญลักษณ์ลูกศรจะแทนลำดับการทำงานในขั้นตอนต่าง ๆ และยังแสดงให้เห็นถึงทิศทางการไหลของข้อมูล ตั้งแต่เริ่มต้นการทำงานจนกระทั่งได้ผลลัพธ์ตาม วัตถุประสงค์ที่ได้ตั้งไว้ โดยการที่จะเขียนผังงานได้นั้น น้อง ๆ จะต้องสามารถวิเคราะห์ระบบการทำงานอย่าง เป็นลำดับขั้นตอนก่อน จากนั้นจึงนำขั้นตอนเหล่านั้นมาเขียนในรูปแบบของผังงานหรือ Flowchart การเขียน Flowchart diagram มีโครงสร้างและวิธีการเขียนที่ค่อนข้างมาตรฐานในตัวอยู่แล้ว เนื่องจากมีการกำหนดสัญลักษณ์ต่าง ๆ ตามมาตรฐานสากลที่ใช้กันทั่วโลก ซึ่งการเขียน Flowchart ให้ สามารถทำความเข้าใจได้ง่ายนั้น ไม่เพียงแค่ต้องใช้สัญลักษณ์ถูกต้องเพียงเท่านั้น แต่จะต้องมีหลักการต่าง ๆ ร่วมด้วย โดยหลักการหรือวิธีการเขียนผังงานที่ดีมีดังนี้

(1) การเขียน Flowchart ควรใช้สัญลักษณ์มาตรฐานตามหลักสากลที่กำหนดไว้โดย The American National Standard Institute, ANSI

(2) เขียน Flowchart โดยใช้ลูกศรแสดงทิศทางการไหลของข้อมูลตามลำดับจากบนลงล่าง หรือจากซ้ายไปขวา

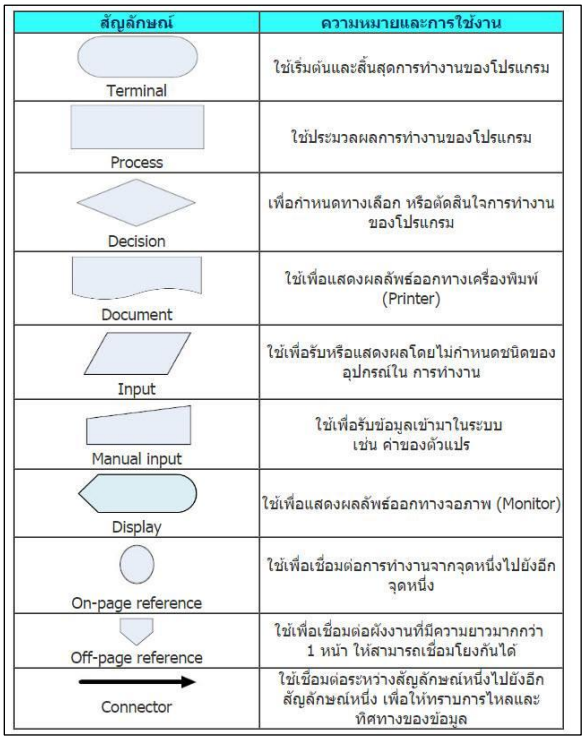
(3) การเขียน Flowchart จะต้องใช้คำอธิบายในแต่ละขั้นตอนให้มีความกระชับและเข้าใจ ง่ายเพื่อเขียนลงในสัญลักษณ์ต่าง ๆ

(4) การเขียนผังงานนั้น ในทุก ๆ สัญลักษณ์ Flowchart จะต้องมีลูกศรแสดงทิศทางเข้า-ออก ของข้อมูลเพื่อความชัดเจน

(5) ในการเขียน Flowchart ไม่ควรโยงเส้นเชื่อมสัญลักษณ์ของผังงานที่อยู่ไกลกัน แต่ควรใช้ สัญลักษณ์จุดเชื่อมต่อเพื่อสื่อสารแทน เนื่องจากการโยงเส้นเชื่อมกันของสัญลักษณ์ Flowchart ที่อยู่ไกลกัน นั้นอาจทำให้สับสนในขั้นตอนการทำงานได้

(6) การเขียนผังงานหรือ Flowchart ควรมีการทดสอบความถูกต้องของอัลกอริทึมก่อนที่จะ นำไปปฏิบัติงานหรือเขียนโปรแกรม

สัญลักษณ์ผังงาน Flowchart การเขียนผังงาน Flowchart นั้นได้มีการกำหนดสัญลักษณ์ที่ใช้งานให้เป็นสากล และเป็นมาตรฐานเดียวกัน โดยการกำหนดมาตรฐานนี้ได้ถูกกำหนดตามแบบของ ANSI (American National Standards Institute) และ ISO (International Standard Organization) เพื่อสื่อความหมาย และให้เกิดความเข้าใจในสัญลักษณ์ที่ใช้ในการเขียนผังงาน Flowchart ทั่วโลก โดยสัญลักษณ์ต่าง ๆ นั้น สามารถแบ่งออกได้เป็นหลายสัญลักษณ์ ดังภาพที่ 2-5 [15]



สัญลักษณ์	ความหมายและการใช้งาน
Terminal	ใช้เริ่มต้นและสิ้นสุดการทำงานของโปรแกรม
Process	ใช้ประมวลผลการทำงานของโปรแกรม
Decision	เพื่อกำหนดทางเลือก หรือตัดสินใจการทำงานของโปรแกรม
Document	ใช้เพื่อแสดงผลลัพธ์ออกทางเครื่องพิมพ์ (Printer)
Input	ใช้เพื่อรับหรือแสดงผลโดยไม่กำหนดชนิดของอุปกรณ์ใน การทำงาน
Manual input	ใช้เพื่อรับข้อมูลเข้ามาในระบบ เช่น ค่าของตัวแปร
Display	ใช้เพื่อแสดงผลลัพธ์ออกทางจอภาพ (Monitor)
On-page reference	ใช้เพื่อเชื่อมต่อการทำงานจากจุดหนึ่งไปยังอีกจุดหนึ่ง
Off-page reference	ใช้เพื่อเชื่อมต่อผังงานที่มีความยาวมากกว่า 1 หน้า ให้สามารถเชื่อมโยงกันได้
Connector	ใช้เชื่อมต่อระหว่างสัญลักษณ์หนึ่งไปยังอีกสัญลักษณ์หนึ่ง เพื่อให้ทราบการไหลและทิศทางของข้อมูล

ภาพที่ 2-5 สัญลักษณ์ Flowchart

2.5 ภาษาที่ใช้ในการพัฒนา

2.5.1 JavaScript / TypeScript

(1) JavaScript

JavaScript เป็นภาษาสคริปต์คอมพิวเตอร์ที่ได้รับความนิยมสูงสุดในหมู่นักพัฒนาซอฟต์แวร์ทั่วโลก เนื่องจากเป็นภาษาที่มีความยืดหยุ่นและสามารถนำไปประยุกต์ใช้ในการสร้างสรรค์ทั้งเว็บไซต์ (Website) และเว็บแอปพลิเคชัน (Web Application) ได้อย่างมีประสิทธิภาพ, โดยมีคุณสมบัติโดดเด่นในการทำงานที่ครอบคลุมทั้งในส่วนของฝั่งผู้ใช้งานหรือหน้าบ้าน (Client-side) และฝั่งเซิร์ฟเวอร์หรือหลังบ้าน (Server-side), หากพิจารณาถึงภูมิหลังทางประวัติศาสตร์ JavaScript ถูกพัฒนาขึ้นครั้งแรกในปี ค.ศ. 1994 โดย Brendan Eich ภายใต้บริษัท Netscape และเปิดตัวในปีถัดมาภายใต้ชื่อ LiveScript ซึ่งในช่วงแรกนั้นถูกมองว่าเป็นภาษาที่ค่อนข้างซับซ้อนและยากต่อการใช้งาน จนกระทั่งในปี ค.ศ. 1997 องค์กร ECMA International ได้เข้ามาสร้างมาตรฐานสากลที่เรียกว่า ECMAScript เพื่อแก้ปัญหาความไม่สามารถสื่อสารข้อมูลข้ามระบบกันได้ของบริษัทฮาร์ดแวร์ต่าง ๆ ในเวลานั้น ส่งผลให้ JavaScript มีรากฐานที่มั่นคงและได้รับการพัฒนาอย่างต่อเนื่องจนกลายเป็นภาษาที่ใช้กันอย่างแพร่หลายในปัจจุบัน JavaScript มีบทบาทสำคัญในการเพิ่มลูกเล่นและการตอบสนองต่อผู้ใช้งานบนหน้าเว็บไซต์ เช่น การเคลื่อนไหวขององค์ประกอบต่าง ๆ การเล่นเสียงและวิดีโอ หรือการเปลี่ยนแปลงรูปแบบของปุ่มเมื่อมีการเลื่อนเมาส์ไปสัมผัส อีกทั้งยังมีความสามารถในการพัฒนาโมบายแอปพลิเคชันผ่านเฟรมเวิร์คอย่าง React Native และการสร้างเกมที่รองรับการตอบสนองบนหน้าเว็บ เช่น เกม TowerBuilding และ Polycraft ซึ่งแสดงให้เห็นถึงความครบถ้วนของฟังก์ชันคำสั่ง, ด้วยความพร้อมของเครื่องมือในการพัฒนาที่มีประสิทธิภาพ อาทิ Visual Studio Code, Atom และ Eclipse รวมถึงช่องทางออนไลน์อย่าง Codepen.io ทำให้ JavaScript กลายเป็นรากฐานสำคัญที่เว็บไซต์กว่าร้อยละ 90 ทั่วโลกเลือกใช้ในการพัฒนาระบบหลังบ้านและโครงสร้างพื้นฐานดิจิทัลในปัจจุบัน [16]

(2) TypeScript

TypeScript คือภาษาการเขียนโปรแกรมที่ได้รับการพัฒนาโดย Microsoft โดยมีพื้นฐานมาจากการต่อยอดและขยายขีดความสามารถของภาษา JavaScript ให้มีประสิทธิภาพ ความปลอดภัย และการบริหารจัดการโค้ดที่ดียิ่งขึ้น โดยเฉพาะในโครงการพัฒนาซอฟต์แวร์ที่มีความซับซ้อนและมีขนาดใหญ่ หัวใจสำคัญของ TypeScript คือการเพิ่มคุณสมบัติการตรวจสอบชนิดของข้อมูลหรือที่เรียกว่า Static Typing ซึ่งช่วยให้นักพัฒนาสามารถระบุประเภทของตัวแปรและตรวจจับข้อผิดพลาดได้ตั้งแต่ในขั้นตอนการเขียนโค้ด ก่อนที่จะมีการนำโค้ดไปรันจริง, กระบวนการทำงานของ TypeScript จะต้องผ่านการคอมไพล์ (Compile) เพื่อแปลงชุดคำสั่งให้กลายเป็น JavaScript

มาตรฐาน เพื่อให้สามารถทำงานบนเว็บเบราว์เซอร์ทุกตัวหรือสภาพแวดล้อมใดก็ได้ที่รองรับ JavaScript ได้อย่างสมบูรณ์ TypeScript สามารถรองรับโครงสร้างการเขียนโปรแกรมเชิงวัตถุ (Object-Oriented Programming – OOP) อย่างเต็มรูปแบบ ผ่านการใช้งานคลาส (Classes) และอินเทอร์เฟซ (Interfaces) ซึ่งช่วยให้นักพัฒนาสามารถสร้างแอปพลิเคชันที่มีโครงสร้างชัดเจน อ่านง่าย และสามารถขยายตัวได้ดีในอนาคต นอกจากนี้ยังมีคุณสมบัติ Generics ที่ช่วยให้การสร้างฟังก์ชันหรือคลาสมีความยืดหยุ่นสูง โดยสามารถทำงานร่วมกับข้อมูลได้หลากหลายประเภทโดยไม่ต้องระบุชนิดข้อมูลที่ตายตัว TypeScript คือการเพิ่มความรวดเร็วและความปลอดภัยในการพัฒนาแอปพลิเคชันผ่านเครื่องมือสนับสนุนที่ครบครัน [17]

2.5.2 JSON

JSON หรือที่มีชื่อเต็มว่า JavaScript Object Notation เป็นรูปแบบหนึ่งในการแลกเปลี่ยนข้อมูลที่ถูกนิยามว่าเป็น "lightweight data-interchange format" หรือรูปแบบการแลกเปลี่ยนข้อมูลที่มีน้ำหนักเบาและมีขนาดกะทัดรัด โดยถูกพัฒนาขึ้นเพื่อให้เป็นสื่อกลางในการสื่อสารและส่งผ่านข้อมูลระหว่างโปรแกรม เว็บไซต์ หรือระบบต่างๆ เพื่อให้แต่ละฝั่งสามารถสื่อสารกันได้อย่างเข้าใจและถูกต้อง ในอดีตการแลกเปลี่ยนข้อมูลมักใช้รูปแบบ XML เป็นหลัก แต่เนื่องจาก XML มีโครงสร้างที่ซับซ้อนและต้องใช้พื้นที่ในการเก็บข้อมูลมากจากส่วนที่เป็น Tag เปิดและปิดจำนวนมาก จึงทำให้ JSON ซึ่งมีรูปแบบที่เรียบง่ายและกระชับกว่าได้รับความนิยมและถูกนำมาใช้ทดแทนอย่างรวดเร็วดังนั้น JSON จึงเป็นรูปแบบข้อมูลที่คอมพิวเตอร์สามารถสร้างและอ่านได้ง่าย และในขณะเดียวกันมนุษย์ก็สามารถทำความเข้าใจได้ไม่ยากเช่นกัน ปัจจุบัน JSON จึงกลายเป็นมาตรฐานสำคัญในการติดต่อสื่อสารผ่าน API (Application Programming Interface) โดยเมื่อมีการดึงข้อมูลผ่าน API ระบบมักจะตอบกลับ (Response) ข้อมูลมาในรูปแบบ JSON ตัวอย่างที่เห็นได้ชัดคือการใช้งานในแพลตฟอร์ม Twitter ที่ใช้ JSON ในการสร้างและส่งข้อมูลของทวีต ซึ่งประกอบไปด้วยข้อมูลเชิงโครงสร้าง เช่น เวลาที่สร้าง ไอดี ข้อความ และข้อมูลผู้ใช้งาน, ดังนั้น JSON จึงเป็นเทคโนโลยีพื้นฐานที่มีความสำคัญอย่างยิ่งในปัจจุบัน เนื่องจากเป็นรูปแบบข้อมูลที่เป็น Text ซึ่งสามารถใช้งานร่วมกับภาษาโปรแกรมได้แทบทุกภาษา [18]

2.5.3 Python

Python คือภาษาการเขียนโปรแกรมระดับสูงที่ได้รับความนิยมอย่างแพร่หลายในปัจจุบัน โดยถูกนำไปใช้งานอย่างกว้างขวางทั้งในด้านการพัฒนาเว็บแอปพลิเคชัน การพัฒนาซอฟต์แวร์ วิทยาศาสตร์ข้อมูล (Data Science) และการเรียนรู้ของเครื่องหรือแมชชีนเลิร์นนิง (Machine Learning) ลักษณะเด่นที่ทำให้ Python แตกต่างจากภาษาอื่นคือการเป็น ภาษาที่แปลผลแล้ว (Interpreted Language) ซึ่งหมายถึงการที่ระบบจะเรียกใช้โค้ดทีละบรรทัดโดยตรง ทำให้โปรแกรมเมอร์สามารถค้นหาและแก้ไขข้อผิดพลาดในโค้ดได้อย่างรวดเร็ว นอกจากนี้ Python ยังมี

รูปแบบไวยากรณ์ที่เรียบง่ายและใกล้เคียงกับภาษามนุษย์หรือภาษาอังกฤษ โดยเลือกใช้การเยื้องหน้ากระดาษ (Indentation) แทนการใช้วงเล็บปีกกาเพื่อกำหนดขอบเขตของโค้ด ซึ่งช่วยลดความซับซ้อนและทำให้นักพัฒนาสามารถอ่านและทำความเข้าใจโปรแกรมได้ง่ายขึ้น Python ยังเป็นภาษาที่มีการระบุประเภทตัวแปรแบบไดนามิก (Dynamic Typing) ซึ่งไม่ต้องระบุประเภทตัวแปรขณะเขียนโค้ดแต่จะถูกกำหนดในระหว่างการทำงาน (Runtime) ส่งผลให้การพัฒนาโปรแกรมทำได้รวดเร็วยิ่งขึ้น อีกทั้งยังมีความเป็นภาษาเชิงอ็อบเจกต์ (Object-Oriented) ที่มองทุกสิ่งเป็นวัตถุ แต่ในขณะเดียวกันก็ยังรองรับโครงสร้างการเขียนโปรแกรมรูปแบบอื่น เช่น การเขียนโปรแกรมเชิงโครงสร้างและเชิงฟังก์ชัน ในเชิงโครงสร้างและระบบนิเวศของภาษา Python มีการสนับสนุนผ่านไลบรารี (Library) และ เฟรมเวิร์ก (Framework) จำนวนมหาศาลซึ่งปัจจุบันมีมากกว่า 137,000 รายการ ไลบรารีเหล่านี้ช่วยลดภาระของนักพัฒนาในการไม่ต้องเขียนโค้ดขึ้นใหม่ทั้งหมดสำหรับงานที่ใช้บ่อย ตัวอย่างเช่น Matplotlib สำหรับการแสดงผลข้อมูลเป็นภาพ NumPy สำหรับการคำนวณทางคณิตศาสตร์และอาร์เรย์ Pandas สำหรับการจัดการข้อมูลที่มีโครงสร้าง และ Keras สำหรับงานด้านนิวรัลเน็ตเวิร์ก ในส่วนของเฟรมเวิร์ก Python มีทั้งแบบฟูลสแตก (Full-stack) อย่าง Django ที่มีเครื่องมือครบถ้วนสำหรับการสร้างแอปพลิเคชันขนาดใหญ่ และไมโครเฟรมเวิร์กอย่าง Flask ที่เหมาะสำหรับแอปพลิเคชันขนาดเล็กและเรียบง่าย นอกจากนี้ยังมีเฟรมเวิร์กเฉพาะทางด้านการเรียนรู้เชิงลึกอย่าง Apache MXNet และ PyTorch ที่นักวิจัยนิยมใช้ในการสร้างโมเดลที่ซับซ้อน [19]

2.6 ทฤษฎีการวัดประสิทธิภาพ (Evaluation Metrics)

2.6.1 การวัดประสิทธิภาพการตรวจจับวัตถุ (Object Detection Metrics)

ในการประเมินประสิทธิภาพของโมเดลการตรวจจับวัตถุ (Object Detection) ทางผู้วิจัยได้เลือกใช้ดัชนีชี้วัดมาตรฐานสากลเพื่อการวิเคราะห์เชิงปริมาณ โดยอาศัยความสัมพันธ์ของค่าการทำนาย 4 องค์ประกอบหลัก ได้แก่ True Positive (TP) หรือการทำนายเป้าหมายถูกต้อง, False Positive (FP) หรือการทำนายผิดพลาดว่าเป็นเป้าหมาย, True Negative (TN) หรือการทำนายตัวอย่างปกติถูกต้อง และ False Negative (FN) หรือเป้าหมายที่แท้จริงแต่โมเดลไม่สามารถตรวจพบได้ ตัวชี้วัดที่ใช้มีรายละเอียดดังต่อไปนี้

(1) ค่าความแม่นยำ (Precision)

ดัชนีชี้วัดสัดส่วนความถูกต้องของการทำนายผลจากกรอบการทำนาย (Prediction box) ว่าเป็นวัตถุเป้าหมายได้อย่างถูกต้อง เมื่อเทียบกับจำนวนผลการคาดการณ์ว่าเป็นเป้าหมายทั้งหมด ค่าประเมินนี้สะท้อนถึงขีดความสามารถของโมเดลในการหลีกเลี่ยงการทำนายผลผิดพลาด (False Positive) สามารถคำนวณได้จากสมการ

$$Precision = \frac{TP}{TP + FP}$$

ภาพที่ 2-6 สมการค่าความแม่นยำ (Precision)

ที่มา: https://www.nerd-data.com/classification-metrics/

(2) ค่าอัตราการค้นพบ (Recall)

ดัชนีที่ระบุถึงสัดส่วนความถูกต้องของการทำนายเมื่อเปรียบเทียบกับกรอบของเป้าหมายที่มีอยู่จริงทั้งหมดในภาพ (Ground Truth) ตัวชี้วัดนี้สะท้อนถึงขีดความสามารถของโมเดลในการตรวจจับรอยโรคหรือแมลงศัตรูพืชได้อย่างครบถ้วน โดยไม่หลุดรอดการตรวจจับ (False Negative) สามารถคำนวณได้จากสมการ

$$Recall = \frac{TP}{TP + FN}$$

ภาพที่ 2-7 สมการค่าอัตราการค้นพบ (Recall)

ที่มา: https://www.nerd-data.com/classification-metrics/

(3) F1-Score

ค่าเฉลี่ยฮาร์มอนิก (Harmonic Mean) ที่คำนวณจากค่า Precision และ Recall เพื่อใช้เป็นดัชนีประเมินความสมดุลของประสิทธิภาพโมเดล ซึ่งเป็นประโยชน์อย่างยิ่งในการชี้วัดประสิทธิภาพร่วมที่ให้ค่าน้ำหนักของความแม่นยำและความครอบคลุมไปพร้อมกัน มักใช้ยืนยันความสามารถของโมเดลร่วมกับค่า Precision และ Recall ในการประเมินผลลัพธ์รวม สามารถคำนวณได้จากสมการ

$$F1\ Score = \frac{2 \times precision \times recall}{precision + recall}$$

ภาพที่ 2-8 สมการค่า F1-Score

ที่มา: https://www.nerd-data.com/classification-metrics/

(4) ค่าความถูกต้องโดยรวม (Accuracy)

ดัชนีชี้วัดประสิทธิภาพที่แสดงถึง "สัดส่วนความถูกต้องของการทำนายทั้งหมด" ไม่ว่าจะเป็นการทำนายเป้าหมาย (เช่น โรคพืชหรือแมลงศัตรูพืช) ได้ถูกต้อง หรือการทำนายพื้นที่ปกติได้อย่างถูกต้อง เมื่อเทียบกับจำนวนตัวอย่างที่นำมาประเมินทั้งหมด ค่านี้สะท้อนถึงภาพรวมว่าโมเดลมีความน่าเชื่อถือและทำงานได้ถูกต้องมากน้อยเพียงใด สามารถคำนวณได้จากสมการ

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

ภาพที่ 2-9 สมการค่าความถูกต้องโดยรวม (Accuracy)

ที่มา: https://www.nerd-data.com/classification-metrics/

(5) mAP (mean Average Precision)

ดัชนีชี้วัดประสิทธิภาพขั้นสูงสุดและถือเป็นเกณฑ์มาตรฐานหลัก (Primary Metric) ที่ใช้ในการประเมินผลการวิจัยด้านโมเดลการตรวจจับวัตถุ (Object Detection) โดยเป็นการประเมินความสามารถของโมเดลในการระบุตำแหน่งและแยกแยะประเภทเป้าหมายในภาพรวมทุกหมวดหมู่ (Classes) ค่า mAP นี้เกิดจากการหาค่าเฉลี่ยของดัชนีย่อยที่เรียกว่า ค่าความแม่นยำเฉลี่ย (Average Precision: AP) ของแต่ละหมวดหมู่เมื่อคำนวณหาค่า AP ของวัตถุเป้าหมายได้ครบ

ทุกหมวดหมู่แล้ว จะนำค่าเหล่านั้นมารวมกันและหารด้วยจำนวนหมวดหมู่ทั้งหมด เพื่อให้ได้ค่าเฉลี่ยชี้วัดประสิทธิภาพในภาพรวมของโมเดล สามารถคำนวณได้จากสมการ [20], [21]

$$mAP = \frac{1}{k} \sum_{i}^{k} AP_i$$

ภาพที่ 2-10 สมการค่า mAP (mean Average Precision)

ที่มา: https://www.superannotate.com/blog/mean-average-precision-and-its-uses-in-object-detection

2.6.2 การวัดประสิทธิภาพระบบดึงข้อมูลเสริม (RAG Evaluation)

กระบวนการประเมินความสามารถของระบบที่ผสานการทำงานระหว่างการค้นคืนข้อมูลจากฐานความรู้ภายนอก (Information Retrieval) และการสร้างคำตอบของโมเดลภาษา (Generation) เป้าหมายเพื่อตรวจสอบว่าระบบสามารถนำเสนอข้อมูลได้ถูกต้อง สอดคล้องกับความต้องการของผู้ใช้ และไม่มีการสร้างข้อมูลเท็จ (Hallucination) จากจินตนาการของโมเดลเอง ตัวชี้วัดที่ใช้มีรายละเอียดดังต่อไปนี้

(1) Context Precision (ความแม่นยำของบริบท)

สัดส่วนของข้อความหรือเอกสารที่ระบบดึงมาได้ (Retrieved passages) ที่มีความเกี่ยวข้อง (Relevant) กับคำถามของผู้ใช้งาน ค่านี้เป็นตัวชี้วัดที่ใช้สะท้อนให้เห็นถึง ความแม่นยำของกระบวนการค้นคืนข้อมูล (Retrieval accuracy) ของระบบ มักใช้เป็นหนึ่งในมาตรวัดย่อยของกรอบการประเมินชุด RAGAS (Retrieval-Augmented Generation Assessment Suite) เพื่อวัดประสิทธิภาพการดึงข้อมูลและประเมินความน่าเชื่อถือของคำตอบ

(2) Faithfulness (ความน่าเชื่อถือ)

ตัวชี้วัดที่ใช้ประเมินว่าข้อความหรือประโยคคำตอบที่โมเดลสร้างขึ้นมานั้น มีหลักฐานสนับสนุนโดยตรงหรือสามารถอนุมานได้จากข้อมูลที่ระบบค้นคืนมาได้ (Retrieved evidence / Provided knowledge) มากน้อยเพียงใด เป้าหมายหลักของการวัด Faithfulness คือ การประเมินความสามารถของโมเดลในการยึดข้อเท็จจริงเป็นหลัก (Grounding) และใช้เป็นตัวชี้วัดเพื่อตรวจสอบว่าโมเดลไม่มีการสร้างข้อมูลเท็จหรือจินตนาการคำตอบขึ้นมาเอง (Absence of hallucination) โมเดลที่มีความน่าเชื่อถือสูงจะช่วยสร้างความไว้วางใจให้กับผู้ใช้งานได้ นอกจากนี้ การประเมิน Faithfulness ยังครอบคลุมไปถึงพฤติกรรมของโมเดลที่จะต้องรู้จัก "ละเว้นหรือปฏิเสธที่จะตอบ" เมื่อพบว่าข้อมูลอ้างอิงที่ระบบดึงมาให้ไม่มีความเกี่ยวข้องกับคำถามเลย

(3) Answer Relevance (ความเกี่ยวข้องของคำตอบ)

ตัวชี้วัดที่ใช้ประเมินความคล้ายคลึงทางความหมาย (Semantic similarity) ระหว่างคำถามของผู้ใช้งานกับคำตอบที่โมเดลภาษา (LLM) สร้างขึ้น จุดประสงค์หลักคือเพื่อวัดว่าระบบสามารถให้ข้อมูลที่ตรงประเด็นกับคำถาม (Topical alignment) ได้ดีเพียงใด โดยทั่วไปมาตรวัดนี้จะถูกนำมาคำนวณให้อยู่ในสเกล 0 ถึง 1 ผ่านการใช้แบบจำลองการฝังคำระดับประโยค (Sentence-level embeddings) และการหาค่าความคล้ายคลึงโคไซน์ (Cosine similarity)

(4) Context Recall (ความครอบคลุมของบริบท)

สัดส่วนของข้อเท็จจริงอ้างอิง (Reference facts) หรือข้อมูลที่เกี่ยวข้องทั้งหมด ที่ปรากฏอยู่ในชุดข้อความที่ระบบดึงมาได้ (Retrieved context) ค่านี้ใช้เป็นตัวชี้วัดเพื่อสะท้อนให้เห็นถึง ความครอบคลุมของการค้นคืนข้อมูล (Retrieval coverage) ว่าระบบสามารถหาและดึงข้อมูลที่จำเป็น "ทั้งหมด" มาให้โมเดลภาษาใช้ประกอบการตอบคำถามได้ครบถ้วนเพียงใด (ต่างจาก Context Precision ที่เน้นว่าสิ่งที่ดึงมานั้นแม่นยำหรือตรงประเด็นแค่ไหน) [22], [23]

2.6.3 การทดสอบการทำงานของระบบ (System Testing)

กระบวนการที่นำเอาส่วนประกอบของระบบ (System components) หรือหน่วยของโปรแกรม (Program units) แต่ละส่วนที่ผ่านการพัฒนาและทดสอบแยกกันแล้ว มาบูรณาการ (Integrate) และทำการทดสอบร่วมกันในฐานะระบบที่สมบูรณ์ ตัวชี้วัดที่ใช้มีรายละเอียดดังต่อไปนี้

(1) การทดสอบเชิงฟังก์ชัน (Functional Testing)

หลักการวิศวกรรมซอฟต์แวร์มักเรียกว่า การทดสอบแบบกล่องดำ (Black-box testing) คือกระบวนการทดสอบที่มุ่งเน้นการตรวจสอบฟังก์ชันการทำงานของระบบ โดยพิจารณาจากพฤติกรรมของระบบผ่านการวิเคราะห์ข้อมูลนำเข้า (Inputs) และผลลัพธ์ที่เกี่ยวข้อง (Outputs) โดยไม่จำเป็นต้องสนใจรายละเอียดการเขียนโค้ดหรือการทำงานภายในของซอฟต์แวร์

(2) การทดสอบประสิทธิภาพด้านความหน่วงเวลา (Performance Testing)

การประเมินพฤติกรรมการทำงานของระบบในเชิงของคุณสมบัติที่ไม่เป็นเชิงฟังก์ชัน (Non-functional requirements) โดยเฉพาะความเร็วในการประมวลผล (Execution time) และเวลาในการตอบสนอง (Response time) คำว่า "ความหน่วงเวลา (Latency)" ในทางวิศวกรรมซอฟต์แวร์หมายถึง ความล่าช้าหรือระยะเวลาที่ใช้ตั้งแต่เริ่มส่งข้อมูลหรือคำสั่ง ไปจนกระทั่งระบบทำงานเสร็จสิ้นและส่งผลลัพธ์กลับมา [24], [25]

2.6.4 การประเมินความพึงพอใจของผู้ใช้งาน (User Satisfaction)

การประเมินผลประสบการณ์ ความรู้สึก และความพึงพอใจที่ผู้ใช้มีต่อระบบ ซึ่งความพึงพอใจและความไว้วางใจของลูกค้านี้เองที่จะช่วยดึงดูดความสนใจจากผู้ใช้งานใหม่ๆ และส่งผลต่อความตั้งใจในการใช้งานอย่างต่อเนื่อง ตัวชี้วัดที่ใช้มีรายละเอียดดังต่อไปนี้

(1) การรับรู้ถึงความง่ายในการใช้งาน (Perceived Ease of Use)

ระดับความเชื่อมั่นหรือการรับรู้ของผู้ใช้งานว่าการโต้ตอบกับระบบนั้นมีความสะดวก ง่ายดาย และไม่ซับซ้อน ซึ่งในบริบทของการประยุกต์ใช้เทคโนโลยีโปรแกรมสนทนาอัตโนมัติ (Chatbot) หรือผู้ช่วยเสมือน (Virtual Assistant) ที่บูรณาการเข้ากับแพลตฟอร์มการสนทนาบนสื่อสังคมออนไลน์ เช่น แอปพลิเคชัน LINE ความสะดวกในการใช้งานจะสะท้อนผ่านความสามารถของระบบที่เปิดโอกาสให้ผู้ใช้งานสามารถติดต่อสื่อสาร สอบถามข้อมูลต่างๆ ได้อย่างเบ็ดเสร็จในจุดเดียว ตลอด 24 ชั่วโมง ช่วยให้ผู้ใช้สามารถป้อนคำถามด้วยข้อความเสมือนการพูดคุยกับมนุษย์จริง

(2) ความน่าเชื่อถือของข้อมูล (Information Reliability)

เทคโนโลยีปัญญาประดิษฐ์เชิงสนทนาได้ถูกนำมาประยุกต์ใช้ในพื้นที่ให้บริการด้านสุขภาพและการแพทย์ (Healthcare applications) อย่างกว้างขวาง โดยทำหน้าที่เป็นผู้ช่วยเสมือนในการให้ข้อมูลทางคลินิก การจัดการดูแลน้ำหนัก การรายงานอาการ การวินิจฉัยโรค ตลอดจนการให้คำแนะนำเกี่ยวกับการใช้ยา (Medication solution) ผ่านระบบบริการทางไกล ดังนั้น ความน่าเชื่อถือของข้อมูลและแนวทางการรักษา (Information Reliability) จึงเป็นตัวแปรสำคัญที่ชี้วัดประสิทธิภาพของระบบ โดยความน่าเชื่อถือนี้จะเกิดขึ้นได้จากการบูรณาการแบบจำลองปัญญาประดิษฐ์และการเรียนรู้เชิงลึก (AI and Deep Learning models) ที่มีความแม่นยำสูง เข้ากับเทคโนโลยีการทำความเข้าใจภาษาธรรมชาติ (Natural Language Understanding - NLU) ที่สามารถวิเคราะห์ สกัดเอนทิตี (Entity Extraction) และตีความเจตนา (Intent) ของผู้ใช้งานที่ป้อนข้อมูลเข้ามาได้อย่างถูกต้อง

(3) ความพึงพอใจโดยรวม (Overall Satisfaction)

ผลรวมของการประเมินประสบการณ์ ความรู้สึก และความไว้วางใจทั้งหมดที่ผู้ใช้งานมีต่อระบบ ผลิตภัณฑ์ หรือการให้บริการ ซึ่งความพึงพอใจโดยรวมนี้ถือเป็นตัวแปรสำคัญที่ช่วยดึงดูดความสนใจจากผู้ใช้งานกลุ่มใหม่ๆ และสะท้อนให้เห็นถึงภาพลักษณ์เชิงบวกขององค์กร นอกจากนี้ ความพึงพอใจของผู้ใช้งานยังเป็นปัจจัยเชิงกำหนด (Determinants) ที่ส่งผลโดยตรงต่อความตั้งใจในการใช้งานระบบอย่างต่อเนื่อง (Continuance intention) และความตั้งใจเชิงพฤติกรรมในการใช้งาน (Behavioral intention to use) ในระยะยาว [26], [27]

2.7 วรรณกรรมที่เกี่ยวข้อง

2.7.1 Vision Meets Language: A RAG-Augmented YOLOv8 Framework for Coffee Disease Diagnosis and Farmer Assistance

ถูกพัฒนาขึ้นโดย Semanto Mondal จาก University of Naples Federico II ประเทศอิตาลี ได้ทำการพัฒนาระบบเกษตรแม่นยำอัจฉริยะ (AI-based precision agriculture

system) เพื่อรวมความสามารถด้านการมองเห็นและภาษาเข้าด้วยกัน มีวัตถุประสงค์เพื่อ ระบุโรคในใบกาแฟและให้คำแนะนำในการรักษาที่สอดคล้องกับบริบท โดยการนำระบบการสืบค้นข้อมูลเสริม (Retrieval-Augmented Generation: RAG) มาใช้ร่วมกับโมเดลภาษาขนาดใหญ่ (LLM) เพื่อลดปัญหาการหลอนของข้อมูล (Hallucinations) และช่วยให้เกษตรกรเข้าถึงแผนการรักษาที่ปรับเปลี่ยนได้ตามสถานการณ์จริง ระบบนี้ช่วยเพิ่มความสะดวกด้วยอินเทอร์เฟซที่ใช้งานง่ายผ่านระบบ Chatbot แบบโต้ตอบ ซึ่งผู้ใช้สามารถส่งรูปภาพใบไม้ที่ติดโรคเพื่อให้ระบบตรวจจับและเสนอวิธีการแก้ไขได้ทันทีผ่านทางหน้าเว็บ แอปพลิเคชันถูกพัฒนาขึ้นโดยใช้เทคโนโลยี YOLOv8 สำหรับการตรวจจับวัตถุ, Llama-3 สำหรับการประมวลผลภาษา, ร่วมกับ FAISS vector store สำหรับการเก็บฐานความรู้ และใช้ LangChain ในการจัดการหน่วยความจำของบทสนทนาเพื่อให้การสื่อสารเป็นไปอย่างต่อเนื่อง [28]

2.7.2 Plant Disease Detection through Multimodal Large Language Models and Convolutional Neural Networks

ถูกพัฒนาขึ้นโดย Konstantinos I. Roumeliotis และคณะ จากภาควิชาสารสนเทศและโทรคมนาคม มหาวิทยาลัย Peloponnese ประเทศกรีซ ร่วมกับนักวิจัยจากมหาวิทยาลัย Cornell และมหาวิทยาลัยเกษตรกรรมแห่งเอเธนส์ ได้ทำการพัฒนาและประเมินประสิทธิภาพของระบบตรวจจับและจำแนกโรคพืชอัตโนมัติ โดยมีวัตถุประสงค์เพื่อเพิ่มความแม่นยำในการวินิจฉัยโรคพืชในระยะเริ่มต้น และลดการพึ่งพาผู้เชี่ยวชาญรวมถึงการเก็บข้อมูลภาคสนามที่ใช้ต้นทุนสูง ระบบนี้ช่วยให้เกษตรกรสามารถตรวจสอบโรคพืชได้โดยตรงบนหน้างาน (On-site diagnosis) ซึ่งช่วยเพิ่มประสิทธิภาพในการจัดการพืชพรรณและสนับสนุนความมั่นคงทางอาหารในรูปแบบเกษตรแม่นยำ จากผลการศึกษาพบว่าแบบจำลองที่ผ่านการปรับจูน (Fine-tuning) สามารถทำความแม่นยำได้สูงสุดถึง 98.12% ในการจำแนกโรคใบแอปเปิล โดยระบบถูกพัฒนาขึ้นด้วยการใช้แบบจำลอง GPT-4o ร่วมกับสถาปัตยกรรม ResNet-50 และใช้ภาษา Python ในการเขียนสคริปต์เพื่อประมวลผลชุดข้อมูล PlantVillage รวมถึงการใช้เทคนิค Bayesian Optimization ผ่านไลบรารี Optuna เพื่อค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุดในการเรียนรู้ [29]

2.7.3 AgriRegion: Region-Aware Retrieval for High-Fidelity Agricultural Advice

ถูกพัฒนาขึ้นโดย Mesafint Fanuel และคณะ จาก North Carolina A&T State University และหน่วยงานพันธมิตรในสหรัฐอเมริกา, ได้ทำการพัฒนาเฟรมเวิร์กสำหรับการดึงข้อมูลที่เสริมด้วยการสร้างคำตอบ (Retrieval-Augmented Generation หรือ RAG) ที่ออกแบบมาเพื่อการให้คำแนะนำด้านเกษตรกรรมโดยเฉพาะ มีวัตถุประสงค์เพื่อแก้ไขปัญหา "การหลอนของข้อมูลตามบริบท" (contextual hallucination) ในโมเดลภาษาขนาดใหญ่ (LLMs) ทั่วไป ซึ่งมักให้คำแนะนำที่ไม่สอดคล้องกับสภาพดิน ภูมิอากาศ หรือข้อกำหนดในแต่ละท้องถิ่น ระบบนี้ถูกออกแบบ

ให้เพิ่มความแม่นยำและความน่าเชื่อถือโดยการฉีดข้อมูลเมตาทางภูมิศาสตร์ (geospatial metadata) และใช้กลไกการจัดลำดับข้อมูลใหม่ตามความสำคัญของภูมิภาค เพื่อให้คำแนะนำในด้านต่างๆ เช่น ตารางการปลูก การควบคุมศัตรูพืช และการใส่ปุ๋ย มีความถูกต้องตามสภาพพื้นที่ของผู้ใช้จริง, จากผลการทดสอบพบว่าสามารถลดการหลอนของข้อมูลลงได้ 10-20% เมื่อเทียบกับระบบ LLM มาตรฐาน และช่วยเพิ่มคะแนนความเชื่อมั่นจากการประเมินอย่างครอบคลุม ในด้านเทคนิค ระบบถูกพัฒนาขึ้นโดยการปรับจูน (fine-tuning) โมเดล LLaMA 3 13B ด้วยชุดข้อมูลคำแนะนำด้านการเกษตรที่ผ่านการคัดกรอง, ใช้เทคโนโลยี OpenAI Ada v2 สำหรับการสร้าง Vector Embedding จากฐานข้อมูลความรู้ทางการเกษตรที่เชื่อถือได้ และใช้ Chroma DB เป็นฐานข้อมูลเวกเตอร์ (Vector Database) เพื่อประสิทธิภาพในการจัดเก็บและดึงข้อมูลเชิงความหมายที่สอดคล้องกับตำแหน่งที่ตั้งของผู้ใช้งาน [30]

เอกสารอ้างอิง

[1] สถาบันวิจัยและพัฒนาแห่งมหาวิทยาลัยเกษตรศาสตร์, *KU สร้างสรรค์ข้าวไทย ศาสตร์แห่งแผ่นดินเพื่อความกินดีอยู่ดี*, มหาวิทยาลัยเกษตรศาสตร์, 2559.

[2] สำนักวิจัยและพัฒนาข้าว กรมการข้าว, *โรคข้าวและการป้องกันกำจัด*, พิมพ์ครั้งที่ 1, กรุงเทพฯ: โรงพิมพ์ชุมนุมสหกรณ์การเกษตรแห่งประเทศไทย จำกัด, 2550.

[3] W. Thongsuk, "Chatbot มีกี่ประเภท มีประโยชน์อย่างไร พร้อมตัวอย่างการใช้งาน," *Talka Talka Digital Agency*, 2567. [ออนไลน์]. เข้าถึงได้จาก: https://talkatalka.com/blog/types-of-chatbot/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[4] ส. มณีแฮด และ ป. วรรณพิรุณ, "ระบบนิเวศการเรียนรู้ดิจิทัลด้วยปัญญาประดิษฐ์สำหรับการเรียนรู้อย่างชาญฉลาด," *วารสารศึกษาศาสตร์ มหาวิทยาลัยนเรศวร*, ปีที่ 21, ฉบับที่ 2, น. 359-373, 2562.

[5] W. X. Zhao *et al.*, "A survey of large language models (v16)," *arXiv preprint arXiv:2303.18223*, 2025. [ออนไลน์]. เข้าถึงได้จาก: https://github.com/RUCAIBox/LLMSurvey.

[6] Y. Zhao *et al.*, "DETRs Beat YOLOs on Real-time Object Detection," *arXiv preprint arXiv:2304.08069*, 2023.

[7] E. Oro *et al.*, "Evaluating Retrieval-Augmented Generation for Question Answering with Large Language Models," in *Proc. Ital-IA 2024: 4th National Conference on Artificial Intelligence*, Naples, Italy, May 29–30, 2024.

[8] J. J. Pan, J. Wang, and G. Li, "Survey of Vector Database Management Systems," *arXiv preprint arXiv*, n.d.

[9] คณะผู้จัดทำ Bizcom, "วิเคราะห์และออกแบบระบบ – ระบบการจัดการความรู้ นักศึกษา bizcom," *GoToKnow*, 2555. [ออนไลน์]. เข้าถึงได้จาก: http://www.bcoms.net/system_analysis/index.asp. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[10] LINE for Business, "คู่มือการใช้งาน LINE Official Account," *LINE for Business*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://lineforbusiness.com/th/. [สืบค้นเมื่อ: 22 ธันวาคม 2568].

[11] LINE Developers Thailand, "Messaging API - สื่อสารและโต้ตอบกับผู้ใช้งานผ่าน Chatbot," *LINE Developers Thailand*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://developers.line.biz/th/services/messaging-api/. [สืบค้นเมื่อ: 22 ธันวาคม 2568].

[12] 9Expert Training, "n8n คืออะไร? เครื่องมือในงานด้าน Agent," *9Expert Training*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://www.9experttraining.com/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[13] A. Piasak, "Pinecone: ขุมพลังฐานข้อมูล Vector สำหรับ AI ยุคใหม่," *Data-Espresso*, 2567. [ออนไลน์]. เข้าถึงได้จาก: https://data-espresso.com/pinecone-vector-database-for-modern-ai/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[14] อาชว์, "คู่มือ: Google Gemini API คืออะไรและใช้งานอย่างไร?," *Apidog*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://apidog.com/th/blog/google-gemini-api-5/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[15] คุณครู Code Genius Academy, "สัญลักษณ์ Flowchart รูปแบบการวางแผนการดำเนินงานอย่างเป็นขั้นตอน," *Code Genius Academy*, 2566. [ออนไลน์]. เข้าถึงได้จาก: https://codegeniusacademy.com/flowchart/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[16] TechUp Team, "มารู้จักกับ JavaScript ภาษาสารพัดประโยชน์แห่งโลกนักพัฒนาซอฟต์แวร์," *TechUp*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://www.techupth.com/articles/what-is-javascript. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[17] KNmasters, "TypeScript คืออะไร? ทำความรู้จักกับภาษาการเขียนโปรแกรมที่พัฒนา JavaScript ให้มีประสิทธิภาพมากขึ้น," *KNmasters*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://www.knmasters.com/typescript/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[18] Developer, "เข้าใจ JSON ใน 5 นาที," *BorntoDev*, 2563. [ออนไลน์]. เข้าถึงได้จาก: https://www.borntodev.com/2020/02/28/what-is-json/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[19] Amazon Web Services, "Python คืออะไร - คำอธิบายเกี่ยวกับภาษา Python," *AWS*, 2568. [ออนไลน์]. เข้าถึงได้จาก: https://aws.amazon.com/th/what-is/python/. [สืบค้นเมื่อ: 26 ธันวาคม 2568].

[20] H. Yang, X. Deng, H. Shen, Q. Lei, S. Zhang, and N. Liu, "Disease Detection and Identification of Rice Leaf Based on Improved Detection Transformer," *Agriculture*, vol. 13, no. 7, p. 1361, Jul. 2023, doi: 10.3390/agriculture13071361.

[21] T. Zhou and L. Wei, "YOLO-DP: A detection model of fifteen common rice diseases and pests," *Springer Nature*, Oct. 2025.

[22] M. Fanuel, M. N. Mahmoud, C. C. Marshall, V. Lakhotia, B. Dari, K. Roy, and S. Zhang, "AgriRegion: Region-Aware Retrieval for High-Fidelity Agricultural Advice," *ACM*, vol. 1, no. 1, pp. 1-15, Dec. 2025, doi: 10.1145/nnnnnnn.nnnnnnn.

[23] V. Adlakha, P. BehnamGhader, X. H. Lu, N. Meade, and S. Reddy, "Evaluating Correctness and Faithfulness of Instruction-Following Models for Question Answering," Mila, McGill University, [Online]. Available: https://github.com/McGill-NLP/instruct-qa.

[24] I. Sommerville, *Software Engineering*, 10th ed. Harlow, England: Pearson Education, 2016.

[25] P. Venkiteela, "n8n: An Open-Source Workflow Automation Platform for Enterprise Integration and AI-Driven Orchestration," *International Journal of Computer Applications*, vol. 187, no. 63, Dec. 2025.

[26] B. P. Wicaksono and A. Zahra, "Design of the use of chatbot as a virtual assistant in banking services in Indonesia," *IAES International Journal of Artificial Intelligence (IJ-AI)*, vol. 11, no. 1, pp. 23-33, Mar. 2022, doi: 10.11591/ijai.v11.i1.pp23-33.

[27] A. Sinha and D. W. Garcia, "Application of Conversational Artificial Intelligence for Farmer's Advisory and Communication," in *Artificial Intelligence and Smart Agriculture*, pp. 63-86, doi: 10.1201/9781003311782-4.

[28] S. Mondal, "Vision Meets Language: A RAG-Augmented YOLOv8 Framework for Coffee Disease Diagnosis and Farmer Assistance," *arXiv preprint arXiv:2505.21544*, 2025.

[29] K. I. Roumeliotis *et al.*, "Plant Disease Detection through Multimodal Large Language Models and Convolutional Neural Networks," *arXiv preprint arXiv:2504.20419*, 2025.

[30] M. Fanuel *et al.*, "AgriRegion: Region-Aware Retrieval for High-Fidelity Agricultural Advice," submitted for publication to *ACM*, 2025.